UNIVERSIDADE DA CORUÑA

Aprendizaje Automático a Gran Escala

Grado en Ciencia e Ingeniería de Datos

Práctica 1: MLlib (2026-2027)

1. **El problema**

   En esta práctica, el objetivo es aplicar las técnicas de aprendizaje automático a gran escala utilizando **Spark MLlib** para resolver un problema de vuestra elección. La tarea consiste en elegir un problema y un conjunto de datos real lo bastante grande como para justificar el uso de Spark.

   Se recomienda buscar conjuntos de datos en plataformas como Kaggle, Hugging Face Datasets, Google Dataset Search, o cualquier otro repositorio de datos públicos.

2. **Objetivos**

   La tarea principal es que los grupos definan, resuelvan y presenten un problema de aprendizaje automático completo, siguiendo un esquema de trabajo riguroso. Para ello, deberán:

   - Elegir un conjunto de datos y un problema (de regresión o clasificación) que se adapte al contexto de "Big Data". Se recomienda que tenga un tamaño considerable (superior a medio millón de filas o 500 MB).
   - Realizar un análisis exploratorio y preprocesar los datos.
   - Entrenar y evaluar varios modelos de **MLlib**.
   - Optimizar hiperparámetros.
   - Analizar y argumentar la validez de los resultados obtenidos y las conclusiones.

   Deberán adquirirse y/o reforzarse estas destrezas:

   - Manipulación de RDDs y DataFrames.
   - Uso de **MLlib** y pipelines de ML.
   - Justificación de la metodología de trabajo.

3. **Metodología y pasos a realizar**

   - **Definición del problema y dataset**: Cada grupo debe seleccionar un problema y un dataset. El profesor revisará la propuesta (presencialmente o por Teams/correo) para asegurar su idoneidad.
   - **Preprocesamiento de datos**: Realizar un análisis preliminar del dataset y las transformaciones necesarias para el entrenamiento de los modelos.

- **Modelado**: Entrenar diferentes modelos de **MLlib** y evaluar su rendimiento utilizando métricas adecuadas para el problema. La elección de la(s) métrica(s) debe estar debidamente justificada en la memoria, explicando por qué son las más apropiadas para el problema escogido.
- Aplicar técnicas de optimización de hiperparámetros (como *GridSearch*) para mejorar el rendimiento del modelo.
- **Presentación oral**: Cada grupo tendrá **5 minutos** para presentar su proyecto en clase (miércoles 29 de octubre). Se debe comentar:
  - El problema planteado y por qué es interesante.
  - El dataset y el preprocesamiento realizado.
  - Los modelos probados y los resultados obtenidos.
  - Las conclusiones y posibles mejoras futuras.

Nota: La nota final de la práctica no se basará únicamente en los resultados obtenidos, sino en la originalidad del problema, la calidad de la presentación y la justificación de la metodología. Adicionalmente, se tendrá en cuenta la capacidad del grupo para responder a las preguntas del público (profesor y/o estudiantes) durante la sesión de presentaciones.

4. **Entrega**

   - La práctica debe realizarse en **grupos de 2 o 3 personas**, siendo los **grupos de 3 la opción preferible**.
   - La entrega se realizará en el Campus Virtual.
   - Documentos a entregar:
     - Un único fichero `.zip` que contenga:
       - Un archivo README.md que asegure la reproducibilidad del proyecto, indicando cómo ejecutar el código.
       - El código de Spark (`.py`) que permita replicar el proyecto de principio a fin de manera "end-to-end", desde la carga de datos hasta la evaluación del modelo.
       - Opcionalmente, un notebook (Jupyter, Colab, etc.) con el análisis exploratorio de datos (EDA) y las pruebas iniciales.
     - Una memoria explicativa de no más de 5 páginas [1] donde se describa la organización del código, se justifique el planteamiento y se analicen los resultados.
   - Los ficheros deberán ser entregados por SÓLO UN miembro del equipo de prácticas.
   - No se admiten entregas pasada la fecha indicada.

Fecha límite de entrega: 23 de octubre de 2026 (hasta las 23:55).

[1] Formato Lecture Notes in Computer Science disponible en `https://es.overleaf.com/latex/templates/springer-lecture-notes-in-computer-science/kzwwpvhwnvfj`

5. **Ejemplos de cursos anteriores:**

   - Predicción de la duración de actividades de running a partir de datos de atletas de larga distancia — dataset
   - Clasificación de retrasos de vuelos en EE.UU. (2019) con variables operativas y meteorológicas — dataset
   - Predicción de precios de carburantes en gasolineras de la provincia de A Coruña (datos MITECO) — dataset
   - Predicción del movimiento bursátil a partir del histórico de más de 9000 tickers — dataset
   - Detección de malware en tráfico de red IoT (dataset IoT-23) — dataset
   - Clasificación de sentimiento en reseñas de productos de Amazon (polaridad positiva/negativa) — dataset
   - Detección de fraude en transacciones financieras móviles (dataset sintético PaySim) — dataset
   - Predicción del tiempo hasta el siguiente incidente de seguridad por organización (Microsoft GUIDE) — dataset
   - Predicción de la severidad de accidentes de tráfico en EE.UU. a partir de datos meteorológicos y geográficos — dataset